



湖南大学
HUNAN UNIVERSITY

人工智能导论

Chapter 1 – 6

人工智能的定义

像人一样思考

合理地思考

像人一样行动

合理地行动

任务环境及环境的种类

➤ 任务环境 (PEAS) 四要素：

➤ 性能 (Performance)

➤ 环境 (Environment)

➤ 执行器 (Actuators)

➤ 传感器 (Sensors)

➤ 种类：完全可观察的 vs. 部分可观察的；单 agent vs. 多 agent；确定的 vs. 随机的；片段式的 vs. 延续式的；静态的 vs. 动态的；离散的 vs. 连续的

搜索算法

- 宽度优先搜索
- 一致代价搜索
- 深度受限的搜索
- 迭代加深的深度优先搜索
- 贪婪最佳搜索
- A*树搜索

搜索算法

- 爬山法
- 模拟退火算法
- 极大极小值算法
- α β 剪枝算法

Chapter 7 & 8 & 9

大纲

➤ 命题逻辑

- 推导证明

- 模型检验

➤ 一阶逻辑

- 语法语义

- 合一

- 前向，反向链接算法

- 归结

命题逻辑：推理

- 模型：“可能世界”
- 如果语句 α 在模型 m 中为真，称 m 满足 α
- 逻辑蕴含： $\alpha \models \beta$ ：如果在使 α 为真的每个模型中， β 也为真
- 逻辑推理算法
 - 可靠性
 - 完备性

命题逻辑：模型检验

- 语句的有效性，可满足性，不可满足性的定义
- 模型检验的方法
 - 真值表枚举算法
 - 推理规则
 - 归结算法
 - 前向链接算法
 - 反向链接算法

一阶逻辑：语义语法

- 全称量词：通常， \Rightarrow 是 \forall 的主要逻辑连接符
- 存在量词：通常， \wedge 是 \exists 的主要逻辑连接符

$$\forall x \forall y = \forall y \forall x$$

$$\exists x \exists y = \exists y \exists x$$

$$\exists x \forall y \neq \forall y \exists x$$

一阶逻辑：合一

- 合一 Know (John, x) 和 know (y, z)
 - $\theta = \{y/\text{John}, x/z\}$ 或者
 - $\theta = \{y/\text{John}, x/\text{John}, z/\text{John}\}$
- 第一个合一置换的结果更加一般化
- 存在唯一的一个最一般合一置换 (MGU)
 - $\text{MGU} = \{y/\text{John}, x/z\}$

一阶逻辑：前向，反向链接算法

➤ 前向链接算法：

- 从知识库的原子语句出发，在前向推理中应用假言推理规则，增加新的原子语句，直至不能进行任何推理。

➤ 反向链接算法：

- 从要证明的结论出发，不断迭代地寻找子目标，直到要证明的子目标就是已知事实

一阶逻辑：归结

➤ 步骤：

- 使用合一置换将一阶逻辑语句中的变量变成常量
- 使用命题逻辑中的归结算法进行证明



湖南大學
HUNAN UNIVERSITY

Chapter 13 & 14 & 18 & 20

大纲

➤ 不确定性量化

- 概率的基本公理
- 先验概率，条件概率
- 贝叶斯规则

➤ 贝叶斯网络

- 条件概率表
- 枚举法精确推理

大纲

➤ 机器学习

- 朴素贝叶斯

- 贝叶斯规则

➤ 人工神经网络

- 感知器算法

➤ 线性模型与支持向量机

- 线性回归与线性分类

- 支持向量机

概率公理

➤ 对于任何命题A, B

➤ $0 \leq P(A) \leq 1$

➤ $P(\text{true}) = 1$ and $P(\text{false}) = 0$

➤ $P(A \vee B) = P(A) + P(B) - P(A \wedge B)$

条件概率, 先验概率, 联合概率

➤ 条件概率: $P(a \mid b) = P(a \wedge b) / P(b)$

➤ e.g. $P(\text{cavity} \mid \text{toothache})$

➤ 先验概率

➤ e.g. $P(\text{Cavity} = \text{true})$

➤ 联合概率

➤ e.g. $P(\text{cavity} \wedge \text{toothache})$

➤ 独立性

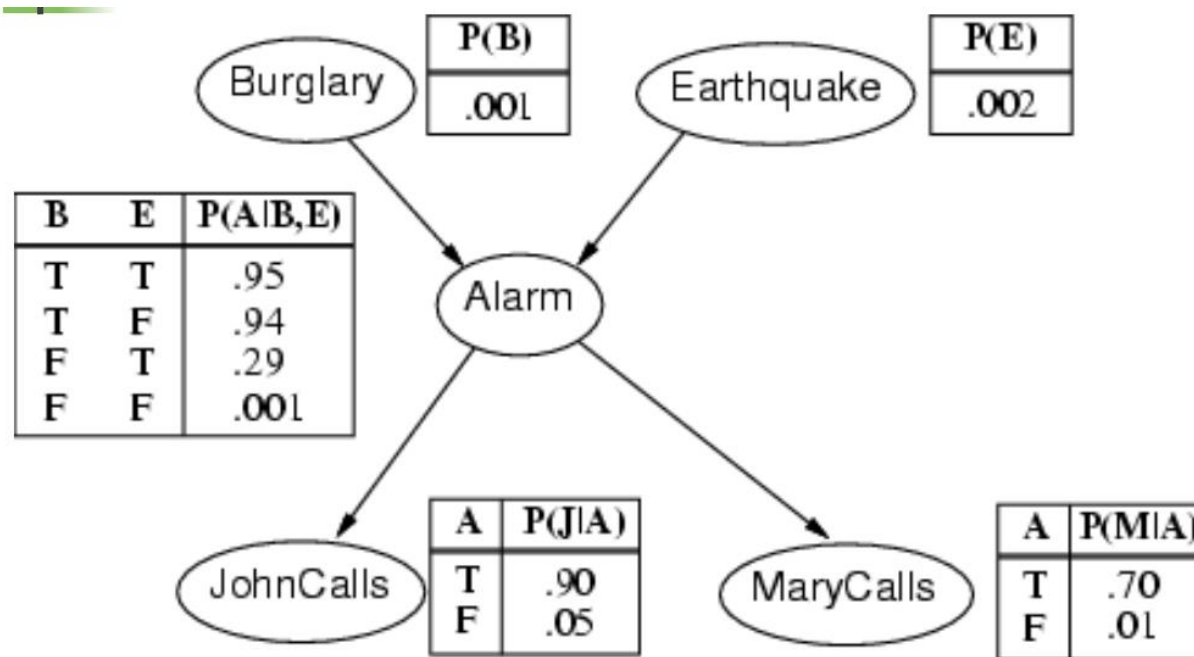
➤ e. g. $P(\text{cavity} \mid \text{toothache}, \text{sunny}) = P(\text{cavity} \mid \text{toothache})$

贝叶斯规则

➤ 贝叶斯规则

➤ $P(a \mid b) = P(b \mid a) P(a) / P(b)$

条件概率表



枚举法精确推理

➤ 枚举法：

$$P(X | e) = \alpha \sum_y P(X, e, y)$$

➤ e. g. 当MaryCalls=true, JohnCalls=true时，出现盗贼的概率是多少？

➤ 查询变量Burglary

➤ 证据变量JohnCalls, MaryCalls

➤ 隐藏变量Earthquake, Alarm

近似推理

- 直接采样法
- 拒绝采样法
- 似然加权法

朴素贝叶斯

NaïveBayesLearn(*examples*)

For each target value v_j

$P'(v_j) \leftarrow \text{estimate } P(v_j)$

For each attribute value a_i of each attribute a

$P'(a_i|v_j) \leftarrow \text{estimate } P(a_i|v_j)$

ClassfyingNewInstance(x)

$$v_{nb} = \underset{v_j \in V}{\operatorname{argmax}} P'(v_j) \prod_{a_j \in x} P'(a_j|v_j)$$

决策树

选择信息收益最大的属性进行分裂

➤ 属性A的信息收益为：原有熵值-属性A分裂后的熵值

$$IG(A) = H([p, n]) - H(A)$$

➤ 一个训练数据集包含p个正样本, n个负样本

$$H([p, n]) = -\frac{p}{p+n} \log_2 P\left(\frac{p}{p+n}\right) - \frac{n}{p+n} \log_2 P\left(\frac{n}{p+n}\right)$$

➤ 一个属性A的取值为 A_1, A_2, \dots, A_v , 根据属性A的取值将训练数据集E分成 E_1, E_2, \dots, E_v , 则属性A的熵值为

$$H(A) = \sum_{i=1}^v \frac{p_i + n_i}{p + n} H\left(\left[\frac{p_i}{p_i + n_i}, \frac{n_i}{p_i + n_i}\right]\right)$$

感知器算法

➤ 第一步：初始化

- 设定初始的权值 w_1, w_2, \dots, w_n 和阈值 θ 为 $[-0.5, 0.5]$ 之间的随机数

➤ 第二步：计算激活函数值

- 根据输入 $x_1(p), x_2(p), \dots, x_n(p)$ 和权值 w_1, w_2, \dots, w_n 计算输出 $Y(p)$ ，其中 p 表示迭代的轮数

感知器算法

➤ 第三步：更新权值

在轮数 p 的错误大小 \longrightarrow $e(p) = Y_d(p) - Y(p)$

理论输出 \nearrow $Y_d(p)$ \nwarrow $Y(p)$ 实际输出

$$\Delta w_i(p) = \alpha \cdot x_i(p) \cdot e(p)$$

学习率 \nearrow α

$$w_i(p + 1) = w_i(p) + \Delta w_i(p)$$

错误大小大于零，则要增大实际输出

线性模型与支持向量机

➤ 线性模型

- 带硬阈值的线性分类器

- 带logistic回归的线性分类器

➤ 支持向量机

机器学习

➤ 强化学习

➤ 深度学习

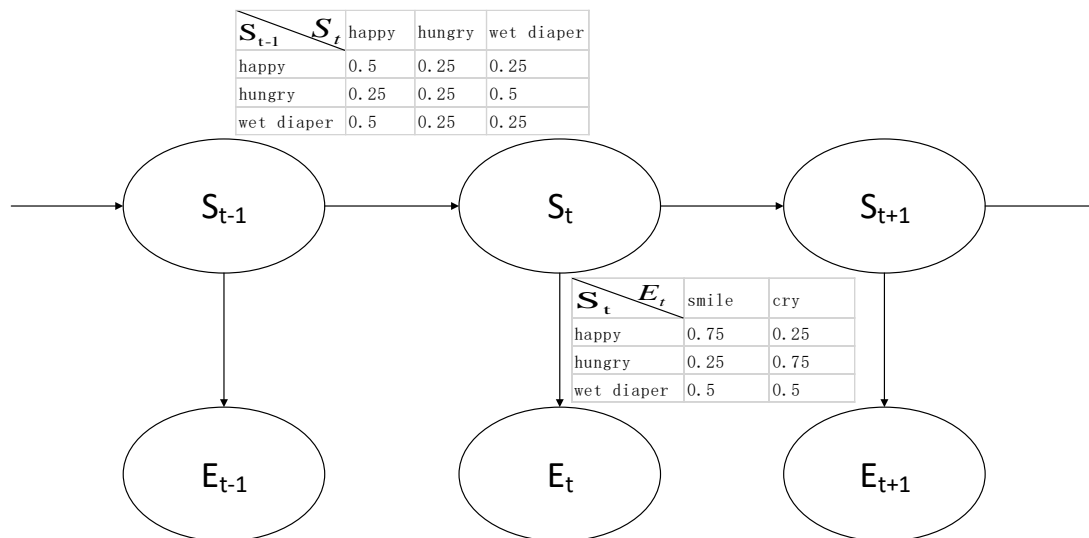
试题讲解

- 安迪是个三个月大的婴儿。他有时快乐(happy), 有时饥饿(hungry), 有时湿尿布(having a wet diaper)。起初, 他在睡完午睡1点醒来, 他很快乐。如果他快乐, 那么在1个小时后他仍有50%的机率保持快乐, 有25%的机会饿着肚子, 另外有25%湿尿布的机会。同样, 如果他饿了, 一小时后他有25%的机会会快乐, 25%的机会仍然饥饿, 另外有50%的机会湿尿布。如果他尿布湿了, 一小时后他会有50%的机会高兴, 25%的机会饿着, 25%的机会湿尿布。当他快乐时, 他有75%的时间微笑(smile), 25%的时间哭(cry)。当他饿了, 他有25%的时间微笑(smile), 75%的时间哭(cry)。当他湿尿布时, 他有50%的时间微笑(smile), 50%的时间哭(cry)。
- a) 根据以上的故事画出HMM模型(画出3个时间节点即可), 并标出相应的传感器概率和转移概率; (8分)
- b) 假定“1pm: smile. 2pm: cry. 3pm: smile”。
- 这个观察序列发生的概率是多少? (5分)
- c) 对于b中对应的最有可能的隐藏状态是什么? (7分)

试题讲解

答:

a): 我们用S表示安迪的状态(happy, hungry, wet diaper), 用E来表示安迪的表情(smile, cry), 其HMM模型如下图所示:



b):

t=1:smile

$$P(1\text{-happy})=1*0.75=0.75$$

t=2:cry

$$P(2\text{-happy})= (P(1\text{-happy})*0.5)*0.25=0.09375$$

$$P(2\text{-hungry})= (P(1\text{-happy})*0.25)*0.75=0.140625$$

$$P(2\text{-wet})= (P(1\text{-happy})*0.25)*0.5=0.09375$$

t=3:smile

$$P(3\text{-happy})= (P(2\text{-happy})*0.5+P(2\text{-hungry})*0.25+P(2\text{-wet})*0.5)*0.75=0.09667969$$

$$P(3\text{-hungry})= (P(2\text{-happy})*0.25+P(2\text{-hungry})*0.25+P(2\text{-wet})*0.25)*0.25=0.02050781$$

$$P(3\text{-wet})= (P(2\text{-happy})*0.25+P(2\text{-hungry})*0.5+P(2\text{-wet})*0.25)*0.5=0.05859375$$

所以, 该序列发生的概率为: $P(1\text{-smile}, 2\text{-cry}, 3\text{-smile})= P(3\text{-happy})+ P(3\text{-hungry})+ P(3\text{-wet})=0.1758$

c):

$$t=2\text{时}, \text{MAX}(P(2\text{-cry}))= P(2\text{-hungry})$$

$$t=3\text{时}, \text{MAX}(P(3\text{-smile}))= P(3\text{-happy})$$

所以, 最有可能的隐藏状态为{1pm:happy, 2pm:hungry, 3pm:happy}

The background features a light gray grid pattern. Overlaid on this are numerous semi-transparent geometric shapes, including squares, rectangles, and triangles, in various shades of blue, green, and purple. Some shapes are solid, while others are outlined or have internal patterns. The overall effect is a complex, layered geometric design.

Qa ?